PROJET RÉALISÉ PAR

L'ÉQUIPE POKÉGIRL DU GROUPE DE TD1

RAPPORT DE GROUPE DES UE BASES DE DONNÉES + SCIENCES DES DONNÉES 2

Fenina Sara, Guilleminot Sarah, Rakoto Ambinintsoa Prisca, Sbircea Stephanie.

Département MIASHS, UFR 6 Informatique, Mathématique et Statistique
Université Montpellier Paul Valéry

Avril 2026

Soumis comme contribution partielle
pour le cours Science des données 2 et Bases de données

Déclaration de non plagiat

À compléter avant la remise du rapport.

Nous déclarons que ce rapport est le fruit de notre seul travail, à part lorsque cela est indiqué explicitement.

Nous acceptons que la personne évaluant ce rapport puisse, pour les besoins de cette évaluation :

- la reproduire et en fournir une copie à un autre membre de l'université ; et/ou,
- en communiquer une copie à un service en ligne de détection de plagiat (qui pourra en retenir une copie pour les besoins d'évaluation future).

Nous certifions que nous avons lu et compris les règles ci-dessus.

En signant cette déclaration, nous acceptons ce qui précède.

Signature : Fenina Sara Date : 30/03/2026

Signature : Guilleminot Sarah Date : 30/03/2026

Signature : Rakoto Ambinintsoa Prisca Date : 30/03/2026

Signature : Sbircea Stephanie Date : 30/03/2026

14 avril 2026

Remerciements

À compléter avant la remise du rapport.

Nos plus sincères remerciements vont à notre encadrant pédagogique pour les conseils avisés sur notre travail.

Nous remercions aussi ...

14 avril 2026

Résumé

L'image ci-dessous vous donne quelques conseils pour rédiger un bon résumé.

general background

specific background

knowledge gap

here we show...

results with key, concrete values

meaning of results

Horizontal gene transfer (HGT), the acquisition of genetic material from non-parental lineages, is known to be important in bacterial evolution[1,2]. In particular, HGT provides rapid access to genetic innovations, allowing traits such as virulence[3], antibiotic resistance[4] and xenobiotic metabolism[5] to spread through the human microbiome. Recent anecdotal studies providing snapshots of active gene flow on the human body have highlighted the need to determine the frequency of such recent transfers and the forces that govern these events[4,5]. Here we report the discovery and characterization of a vast, human-associated network of gene exchange, large enough to directly compare the principal forces shaping HGT. We show that this network of 10,770 unique, recently transferred (more than 99% nucleotide identity) genes found in 2,235 full bacterial genomes, is shaped principally by ecology rather than geography or phylogeny, with most gene exchange occurring between isolates from ecologically similar, but geographically separated, environments. For example, we observe 25-fold more HGT between human-associated bacteria than among ecologically diverse non-human isolates ($P = 3.0 \times 10^{-270}$). We show that within the human microbiome this ecological architecture continues across multiple spatial scales, functional classes and ecological niches with transfer further enriched among bacteria that inhabit the same body site, have the same oxygen tolerance or have the same ability to cause disease. This structure offers a window into the molecular traits that define ecological niches, insight that we use to uncover sources of antibiotic resistance and identify genes associated with the pathology of meningitis and other diseases.

All rights reserved by Nature. Reproduced here for educational purposes only.

The human body is a complex biological network comprising ten

Table des matières

Chapitre 1 Introduction 1

Chapitre 2 Base de données 2
- 2.1 Provenance des données 2
- 2.2 Descriptif des tables 2
- 2.3 Modèles MCD et MOD 5
  - 2.3.1 MCD 5
  - 2.3.2 MOD : 6
- 2.4 Import des données 7
  - 2.4.1 Transformation du fichier Json en csv : 7
  - 2.4.2 Création des nouveaux Trainer ID : 7
  - 2.4.3 Création des tables dérivées de WonderTrade : 8
  - 2.4.4 Dernières modifications : 8
- 2.5 Requêtes réalisées 8
- 2.6 Quelques détails techniques 8

Chapitre 3 Matériel et Méthodes 9
- 3.1 Logiciels 9
- 3.2 Modélisation statistique 9

Chapitre 4 Analyse Exploratoire des Données 10

Chapitre 5 Inférence statistique et modélisation 11
- 5.1 La droite de régression linéaire : un premier exemple 11

Chapitre 6 Discussion 12

Chapitre 7 Conclusion et perspectives 13

Bibliographie 14

Annexes 15
- **Codes** 15
- **Tables** 15

Chapitre 1

Introduction

Dans le cadre de ce projet, nous nous intéressons au système d'échange Wonder Trade du jeu vidéo Pokémon Sun and Moon, qui permet aux joueurs d'échanger des Pokémon de manière aléatoire avec d'autres joueurs à travers le monde. Ce système constitue un exemple intéressant d'interactions entre joueurs, où les décisions d'échange peuvent refléter des stratégies, des préférences ou encore une certaine gestion des ressources disponibles dans le jeu. En effet, chaque joueur dispose de Pokémon ayant des caractéristiques différentes, notamment en termes de puissance, de rareté ou de type, ce qui peut influencer leur choix de les conserver ou de les échanger.

caractéristiques statistiques d'un Pokémon (puissance, rareté, type) influencent-elles sa probabilité d'être échangé dans le système Wonder Trade de Pokémon Sun and Moon ?

Ainsi, on peut se demander si les échanges réalisés dans le Wonder Trade sont réellement aléatoires du point de vue de la qualité des Pokémon, ou s'ils révèlent des comportements spécifiques de la part des joueurs. Autrement dit, les joueurs ont-ils tendance à échanger des Pokémon moins performants ou moins rares, ou observe-t-on également la présence de Pokémon puissants et recherchés dans ce système ? Cette interrogation est centrale pour comprendre la logique des échanges et les stratégies adoptées par les joueurs.

Cette question présente un intérêt à la fois en analyse de données et en compréhension des comportements dans les environnements numériques. En effet, si les joueurs échangent majoritairement des Pokémon faibles ou communs, cela pourrait indiquer une logique d'optimisation individuelle. À l'inverse, la présence de Pokémon rares ou puissants dans les échanges pourrait révéler des comportements différents, comme la recherche d'aléatoire, la générosité ou des stratégies spécifiques. Ainsi, l'étude de cette problématique permet de mieux comprendre les dynamiques d'échange dans ce système et d'appliquer des outils statistiques pour analyser ces comportements.

#Rôles

Fenina Sara : Étudiante n°22411291, Resp. de la collecte des données.
Guilleminot Sarah : Étudiante n°22405827, Resp. recherche bases de données.
Rakoto Ambinintsoa : Étudiante n°22402951, Resp. Descriptif des tables.
Sbircea Stephanie : Étudiante n°22304694, Resp. import des données.

Chapitre 2

Base de données

2.1 Provenance des données

pokemon : https://www.kaggle.com/datasets/rounakbanik/pokemon) et data_world : (https://data.world/notgibs/pokemon-wonder-trade-results/workspace/file?filename=Wonder+Trade.csv)

On a sélectionné la table pokemon car elle contient les données relatives à la description des Pokémon, et la table wonder trade car elle contient les informations concernant les échanges.

Les données sont stockées sous format CSV : le fichier pokemon.csv contient 38 colonnes et 802 lignes, tandis que le fichier wonder trade.csv contient 15 colonnes et 501 lignes.

Afin de faciliter l'analyse, nous avons choisi de filtrer certaines colonnes. En effet, toutes les variables n'étaient pas nécessaires pour répondre à notre problématique.

Dans la table pokemon, nous avons conservé uniquement les colonnes les plus pertinentes, notamment celles liées aux caractéristiques principales comme les statistiques (attack, defense, speed, base_total), les types (type1, type2), ainsi que des informations générales comme la génération et le caractère légendaire.

Dans la table wonder trade, nous avons également sélectionné un sous-ensemble de colonnes parmi les 15 colonnes initiales, en conservant celles décrivant les échanges (niveau, région, nature, objets, etc.).

Ce filtrage permet de réduire le nombre de variables tout en gardant les informations essentielles, ce qui rend l'analyse plus claire et plus pertinente.

Concernant les lignes, nous avons choisi de conserver l'ensemble des observations, soit 802 Pokémon et 501 échanges, afin de ne pas biaiser les résultats et de garder une vision globale des données.

La population étudiée correspond à l'ensemble des Pokémon du fichier pokemon.csv ainsi qu'aux échanges du fichier wonder trade.csv.

2.2 Descriptif des tables

La table Pokemon sert de dictionnaire de référence. Elle contient toutes les statistiques immuables et globale de chaque espèce de Pokémon (force, types, résistances).

Table 2.1: Table : pokemon (802×41)

Nom colonne	**Type**	**Signification**	**Caractéristique**
id_pokemon	Entier	Identifiant interne du Pokémon	**Clé primaire**
pokedex_number	Entier	Numéro officiel du Pokédex	Unique par espèce
name	Chaîne	Nom anglais de l'espèce	EX : Abra
abilities	Liste	Capacités spéciales possibles	EX : ['Overgrow']
type1 / type2	Chaîne	Types élémentaires	type2 peut être **vide** (NULL)
hp/attack/defense/sp_attack/sp_defense/speed	Entier	Statistiques de combat de base	Valeurs numériques (ex : 45, 120)
base_total	Entier	Somme des statistiques	Puissance globale
is_legendary	Booléen	Statut de Pokémon légendaire	0 = Non, 1 = Oui
against_water / bug / fire / etc.	Réel	Multiplicateurs de dégâts subis	0.5 = Résistant, 1 = Neutre, 2 = Faible

Table 2.2: Table : trades

Nom colonne	**Type**	**Signification**	**Caractéristique**
pokemonId	Entier	ID du Pokémon échangé	**Clé étrangère** vers pokemon
trainerId	Entier	ID du dresseur partenaire	**Clé étrangère** vers trainers
userId	Entier	ID de l'utilisateur local	**Clé étrangère** vers users
level	Entier	Niveau du Pokémon lors de l'échange	EX : 26 (peut être importé en texte)
isShiny	Texte	Aspect chromatique rare	"VRAI" ou "FAUX"
hasItem	Texte	Le Pokémon tient-il un objet ?	"VRAI" ou "FAUX"
hasHiddenAbility	Texte	Possède un talent caché rare	"VRAI" ou "FAUX"
hasPerfectIV	Texte	Possède des stats innées au max	"VRAI" ou "FAUX"
hasPokerus	Texte	Infecté par le virus bénéfique	"VRAI" ou "FAUX"
hasEggMove	Texte	Possède une capacité de reproduction	"VRAI" ou "FAUX"

Nom colonne	Type	Signification	Caractéristique
liked	Chaîne	Avis de l'utilisateur sur l'échange	"like", "dislike" ou **vide**
date / time	Date / Heure	Moment précis de l'échange	EX : 2015-02-08 / 54817

La table Trades est centrale. Elle enregistre l'historique de tous les échanges effectués. Contrairement à la table précédente, les données ici (niveau, objet, shiny) sont spécifiques au spécimen précis qui a été reçu lors de l'échange.

Table 2.3: Table : trainers

Nom colonne	Type	Signification	Caractéristique
id_trainer	Entier	Identifiant unique du dresseur	**Clé primaire**
trainer_name	Chaîne	Pseudo du dresseur	Peut être **vide** (si anonyme)
gender	Chaîne	Sexe du dresseur	"male" ou "female"
country	Chaîne	Code pays (ISO)	EX : US, JP, FR
country_sub1	Chaîne	Région ou État d'origine	EX : California, Texas, Tokyo

La table Trainers contient les profils des partenaires d'échange. Elle permet de savoir avec qui l'utilisateur a interagi et de quelle région du monde provient le Pokémon reçu.

Table 2.4: Table : users

Nom colonne	Type	Signification	Caractéristique
id_user	Entier	Identifiant unique de l'utilisateur	**Clé primaire**

La table Users est très courte et sert simplement à identifier les comptes locaux sur le logiciel du site web qui a enregistré les données.

2.3 Modèles MCD et MOD

2.3.1 MCD

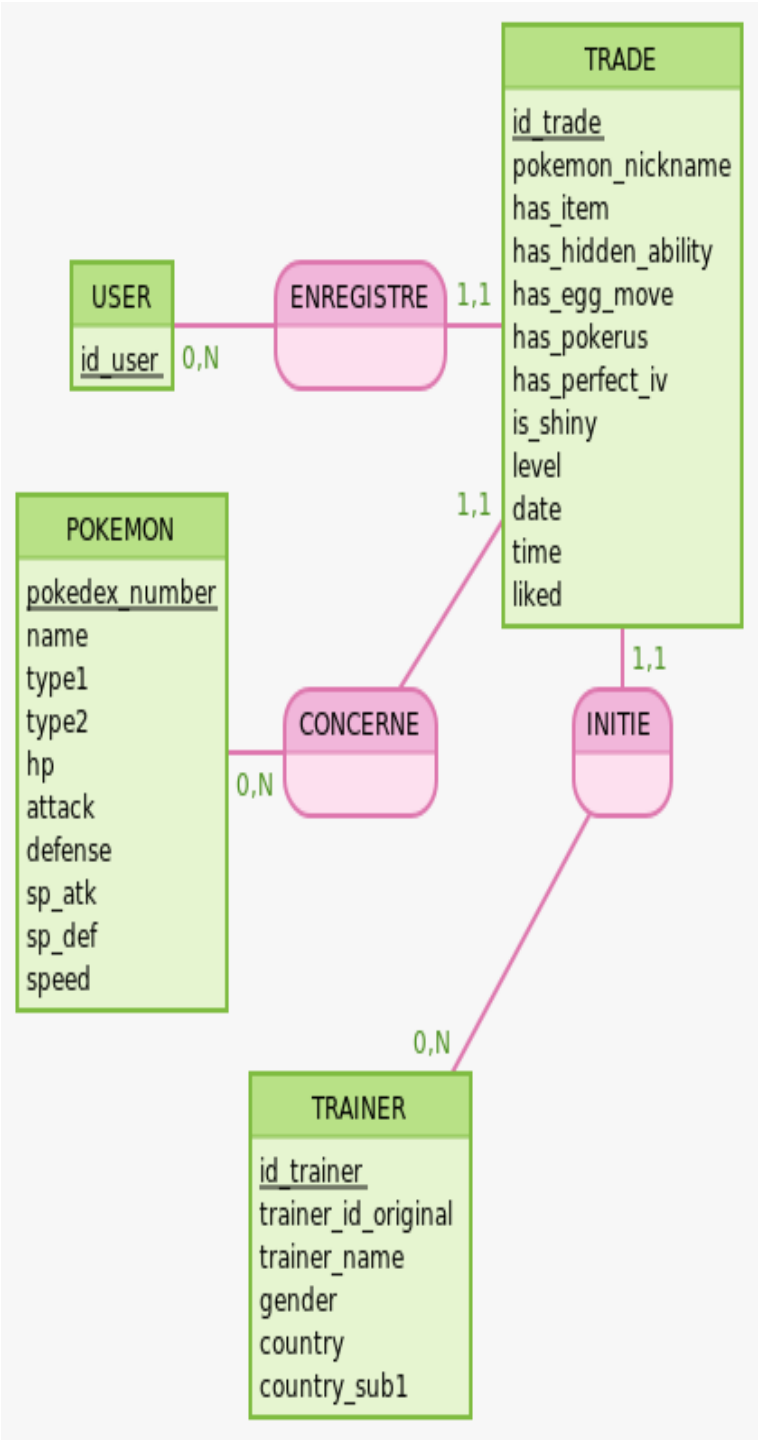

FIGURE 2.1: **MCD**.

2.3.2 MOD :

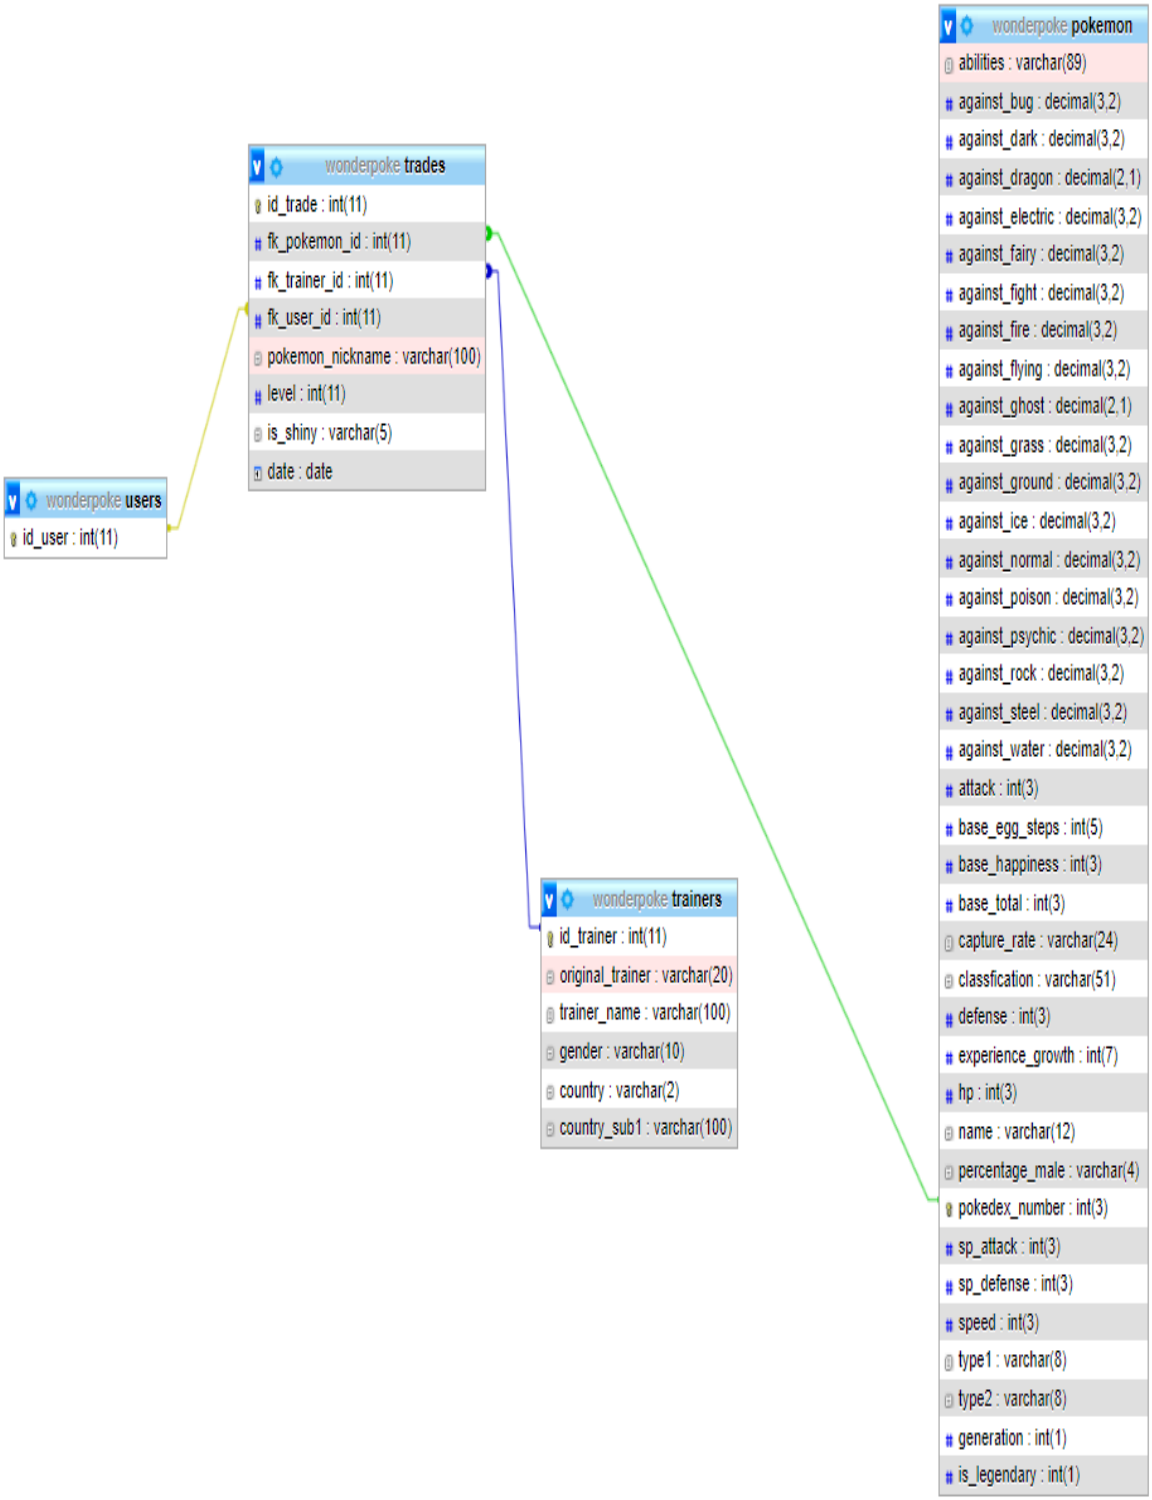

FIGURE 2.2: ** MOD.**

MOD :
USERS (id_user)
TRAINER (id_trainer, original_trainer_id, trainer_name, gender, country, country_sub1)
POKEMON (pokedex_number, name, abilities, classification, type1, type2, hp, attack, defense, sp_attack, sp_defense, speed, base_total, base_happiness, base_egg_steps, experience_growth, percentage_male, capture_rate, against_bug, against_dark, against_dragon, against_electric, against_fairy, against_fight, against_fire, against_flying, against_ghost, against_grass, against_ground, against_ice, against_normal, against_poison, against_psychic, against_rock, against_steel, against_water, is_legendary, generation)
TRADE (id_trade, pokemon_nickname, has_item, has_hidden_ability, has_egg_move, has_pokerus, has_perfect_iv, is_shiny, level, date, time, liked, #id_user, #id_trainer, #pokedex_number)

2.4 Import des données

A partir des fichiers **Pokemon** et **WonderTrade**, nous avons créé les tables **Pokemon**, **Trades**, **Trainers** et **Users** comme indiqué si-dessous.

2.4.1 Transformation du fichier Json en csv :

Nous avons importé le fichier **WonderTrade** qui est en Json sur Excel en allant sur "obtenir des données" puis "à partir d'un fichier" puis "à partir de JSON" comme le montre la Figure.1, ce qui nous a permi de le convertir en table avec l'éditeur Power Query.

Nous avons choisi de garder toutes les colonnes en cliquant sur la double flèche et en sélectionnant le tout comme le montre la Figure.3, puis nous avons pu avoir le fichier en csv grâce au bouton "fermer et charger".

2.4.2 Création des nouveaux Trainer ID :

Directement dans le fichier CSV **WonderTrade** ouvert dans LibreOffice, nous avons procédé de la manière suivante :

Nous avons d'abord activé l'autofiltre sur l'ensemble des données afin de faciliter les opérations de tri, pour ensuite trier par ordre croissant ***trainerGender*** puis ***TrainerCountry*** puis ***TrainerCountrySub1***.

Ce tri permet de regrouper les lignes présentant des caractéristiques similaires, ce qui est nécessaire pour la suite du traitement.

Nous avons ensuite trié la colonne ***trainerId*** par ordre croissant. Nous avons constaté que les lignes situées en bas du tableau correspondent aux échanges avec un trainerId vide. Ce sont ces lignes pour lesquelles nous devons créer de nouveaux identifiants.

Nous faisons ici l'hypothèse que des individus ayant le même genre, le même pays et la même sous-localisation correspond à une seule et même personne. Sachant qu'il

y a environ 100 lignes sans ID et que les identifiants existants commencent à 783, il n'y aura pas de problème pour créer les nouveaux.

Sous le dernier ***trainerId*** connu, nous saisissons la valeur 1, puis dans la cellule suivante, nous entrons la formule :

```
“=SI(J103=J104;SI(K103=K104;SI(L103=L104;Q103;Q103+1);Q103+1);Q103+1)”
```

Nous étirons ensuite cette formule jusqu'à la dernière ligne du tableau.

Cette formule permet de comparer chaque ligne à la précédente : si le genre, le pays et la sous-localisation sont identiques, l'identifiant reste le même ; dans le cas contraire, il est incrémenté de 1.

Nous avons choisi cette méthode en considérant que les trainers partageant les mêmes caractéristiques correspondent à une seule personne. Il aurait également été possible d'attribuer un identifiant distinct à chaque trainer anonyme, mais ce choix n'a pas d'impact sur notre analyse, qui porte sur les caractéristiques des individus (genre, pays, etc.) et non sur leur identification individuelle.

2.4.3 Création des tables dérivées de WonderTrade :

À partir du fichier **WonderTrade** modifié, nous avons construit plusieurs tables :

Users contenant uniquement la colonne ***userId***

Trades avec les colonnes suivantes : ***id_trade, hasItem, hasHiddenAbility, hasEggMove, hasPokerus, hasPerfectIV, isShiny, level, date, time, liked, #id_user, #id_trainer, #pokedex_number***

Trainers avec les colonnes suivantes : ***id_trainer, trainerGender, trainerCountry et trainerCountrySub1***

2.4.4 Dernières modifications :

Table **Pokemon** : Nous avons ouvert le fichier CSV pokemon avec LibreOffice afin de supprimer les colonnes inutiles, notamment ***weight*** et ***height***

Tables **Traders** et **Users** : Nous avons ouvert ces tables dans LibreOffice, puis nous avons trié les données par identifiant croissant, et enfin nous avons ensuite supprimé manuellement les lignes en double.

Table **Trades** : Nous avons ajouté une clé primaire auto-incrémentée directement dans phpMyAdmin en utilisant la requête SQL suivante :

```
“ALTER TABLE trades ADD IdTrade INT AUTO_INCREMENT PRIMARY KEY;”
```

2.5 Requêtes réalisées

2.6 Quelques détails techniques

Chapitre 3

Matériel et Méthodes

3.1 Logiciels

3.2 Modélisation statistique

Chapitre 4

Analyse Exploratoire des Données

Chapitre 5

Inférence statistique et modélisation

5.1 La droite de régression linéaire : un premier exemple

Chapitre 6

Discussion

Chapitre 7

Conclusion et perspectives

Bibliographie

Annexes

Codes

Tables

1. Table Markdown
2. Table Latex